

Sistema de Clasificación Automática de Residuos mediante Redes Convolucionales Usando un Dataset Propio

Cartagena Valera Brush, Davis Leonardo¹. Martinez Ochoa, Santos Eduardo². Suarez Bautista, Pablo Israel³. Santillan Chihuala, Paul Gustavo Gabriel⁴. Rugel Alva, Miguel Aarom⁵. Sosa Lupuche, Carlos Manuel⁶

¹22200193 – davis.cartagena@unmsm.edu.pe

²20200098 – santos.martinez1@unmsm.edu.pe

³22200132 – pablo.suarez2@unmsm.edu.pe

⁴21200071 – paul.santillan@unmsm.edu.pe

⁵21200037 – miguel.rugel@unmsm.edu.pe

⁶22200197 – carlos.sosa5@unmsm.edu.pe

I. Introducción

El incremento sostenido de los residuos sólidos representa un reto ambiental significativo para la mayoría de ciudades. La inadecuada segregación de residuos limita los procesos de reciclaje y aumenta la contaminación del entorno. La automatización de este proceso mediante visión artificial y técnicas de aprendizaje profundo se presenta como una solución eficiente y escalable.

Las Redes Neuronales Convolucionales (CNN) se han consolidado como la técnica estándar para clasificación de imágenes debido a su capacidad para aprender características jerárquicas directamente desde los datos (LeCun, Bengio & Hinton, 2015). Investigaciones previas han demostrado su eficacia en tareas de reconocimiento en gran escala, como el caso de AlexNet (Krizhevsky et al., 2012).

Diversos estudios recientes aplican CNN al problema de clasificación de residuos, como TrashNet (Yang & Thung, 2016) o sistemas automatizados de separación (Rohit et al., 2019). No obstante, existe una brecha importante en datasets locales. Por ello, en este proyecto se propone un modelo CNN entrenado con un dataset propio, construido con imágenes reales tomadas en diferentes condiciones. El objetivo es desarrollar un sistema capaz de identificar imágenes nuevas como plástico, papel u orgánico, con un desempeño adecuado para un prototipo funcional.

II. Contexto y Justificación

Clasificar residuos de forma manual es un proceso ineficiente y altamente propenso a errores. La automatización mediante visión artificial no solo mejora la precisión, sino que contribuye a la gestión sostenible de residuos. La literatura muestra que los modelos CNN logran resultados sobresalientes debido a su habilidad para detectar patrones visuales complejos (LeCun et al., 2015).

La creación de un dataset propio añade valor agregado al proyecto, permitiendo entrenar un modelo adaptado a las condiciones locales: tipos reales de desechos, iluminación variable, fondos comunes y texturas propios del entorno. Esto mejora la aplicabilidad del modelo en contextos reales, algo que datasets genéricos no garantizan.

III. Objetivo General y objetivos específicos

Objetivo General:

Desarrollar un sistema de clasificación automática de residuos basado en una Red Neuronal Convolucional, utilizando un dataset propio y capaz de identificar imágenes de plástico, papel y residuos orgánicos.

Objetivos Específicos:

- Construir y organizar un dataset propio de imágenes clasificadas en tres categorías.
- Preprocesar las imágenes aplicando técnicas de normalización y data augmentation.
- Implementar una CNN estilo VGG para clasificación multiclase.
- Entrenar y validar el modelo utilizando TensorFlow y Keras.
- Evaluar el rendimiento mediante métricas como accuracy, pérdida y matriz de confusión.
- Implementar un script para clasificar imágenes nuevas en tiempo de ejecución.

IV. Alcance y delimitaciones

El sistema se restringe a tres clases de residuos: plástico, papel y orgánico. El dataset fue recolectado de forma manual y mediante búsqueda controlada en línea, lo que implica variabilidad limitada en las condiciones de captura. El sistema clasifica una sola imagen a la vez, sin detección de múltiples objetos ni segmentación semántica. No se integró

con hardware IoT, aunque la arquitectura permite ello como trabajo futuro.

V. Metodología

El dataset fue organizado con la siguiente estructura:

```
dataset/  
  train/  
    plastico/  
    papel/  
    organico/  
  val/  
    plastico/  
    papel/  
    organico/
```

Cada carpeta contiene entre 40 y 80 imágenes por clase, en formatos reproducibles por TensorFlow. Para evitar sesgos se recolectaron imágenes de diferentes ángulos, fondos y condiciones de iluminación.

Preprocesamiento

Las imágenes fueron:

- Redimensionadas a 224×224 px
- Normalizadas al rango [0,1]
- Aumentadas mediante rotaciones, zooms y flips, siguiendo recomendaciones de Shorten & Khoshgoftaar (2019)

Estas técnicas permiten mejorar la capacidad del modelo para generalizar.

Arquitectura de la CNN

. Se implementó una arquitectura inspirada en VGG-like:

Bloque 1: 32 filtros, Conv2D + BatchNorm + Conv2D + MaxPooling

Bloque 2: 64 filtros

Bloque 3: 128 filtros

Capa densa de 256 neuronas + Dropout

Capa softmax de salida con 3 clases

Se empleó el optimizador Adam y la función de pérdida categorical cross-entropy.

Entrenamiento del Modelo

El modelo fue entrenado por 5–10 épocas, con batch size de 32. TensorFlow permitió la ejecución en CPU de manera eficiente (Abadi et al., 2016). Las curvas de accuracy y loss mostraron una convergencia estable sin síntomas de sobreajuste extremo.

Evaluación

La efectividad del modelo se evaluó mediante:

Accuracy en entrenamiento y validación

Matriz de confusión

Tasa de predicción correcta por clase

Pruebas con imágenes externas no incluidas en el dataset

El modelo fue posteriormente exportado en formato .h5 para permitir su uso en un script de predicción independiente.

VI. Resultados

El modelo logró clasificar correctamente una proporción significativa de imágenes, alcanzando una precisión competitiva considerando el tamaño del dataset. La clase plástico presentó mayor precisión, mientras que orgánico fue la más desafiante debido a su diversidad visual.

En pruebas externas, el modelo demostró ser capaz de predecir correctamente residuos comunes con niveles altos de

confianza, lo que coincide con estudios similares como TrashNet (Yang & Thung, 2016).

El script de predicción permitió cargar imágenes desde el sistema de archivos y obtener una clasificación inmediata, generando probabilidades por clase y un diagnóstico final. Esto valida la viabilidad del sistema como un primer prototipo funcional.

VII. Conclusiones

- Se desarrolló exitosamente un sistema de clasificación de residuos basado en CNN.
- El dataset propio permitió ajustar el modelo a condiciones reales del entorno.
- El sistema logró una precisión adecuada para un prototipo académico o funcional básico.
- La metodología empleada es escalable y aplicable a sistemas IoT, móviles o web.

VIII. Referencias

- Abadi, M., et al. (2016). TensorFlow: Large-scale machine learning on heterogeneous distributed systems. Google Research. <https://arxiv.org/abs/1603.04467>
- Chollet, F. (2015). Keras: Deep Learning for Python. <https://keras.io>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097–1105.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521, 436–444.
- Rohit, M., Kumar, A., & Goyal, N. (2019). Automatic waste segregation using deep learning. *International Journal of Innovative Technology and Exploring Engineering*, 8(9), 2278–2283.
- Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(60). <https://doi.org/10.1186/s40537-019-0197-0>
- Yang, M., & Thung, G. (2016). Classification of trash for recyclability status. Stanford University. <https://cs.stanford.edu/people/shiry/TrashNet>